Advanced Machine Learning என்பது **basic machine learning techniques-ஐ** விட அதிகமான **advanced methods, algorithms, optimization techniques** பயன்படுத்தி **complex problems solve** செய்வது.

Simple-ஆ சொல்ல வேண்டுமென்றால் 👇

> **Advanced ML =** பெரிய மற்றும் சிக்கலான **data-ஐ analyze** செய்து மிகவும் **accurate prediction** செய்யும் **machine learning techniques.**

1️⃣ Basic ML vs Advanced ML

Basic ML	Advanced ML
Simple algorithms	Complex algorithms
Small datasets	Large datasets
Few features	Feature engineering
Basic prediction	High accuracy prediction

Example:

Basic ML → Simple **Linear Regression**
Advanced ML → **Deep Learning Neural Network**

2️⃣ Advanced ML Techniques

Advanced ML-ல் பொதுவாக பயன்படுத்தப்படும் techniques:

1. Feature Engineering

Data-ஐ model க்கு **best format-ஆ** மாற்றுவது.

Example
Date → Year, Month, Day split

---

2. Feature Selection

Important columns மட்டும் தேர்வு செய்வது.

Example
House price prediction:

✔ Size
✔ Location

❌ Owner name

---

3. Ensemble Learning

பல models சேர்த்து prediction செய்வது.

Example algorithms:

- Random Forest
- Gradient Boosting
- XGBoost
- LightGBM

---

4. Hyperparameter Tuning

Model parameters-ஐ **optimize** செய்வது.

Methods:

- Grid Search
- Random Search
- Bayesian Optimization

---

5. Deep Learning

Artificial Neural Networks பயன்படுத்தி learning செய்வது.

Used for:

- Image Recognition
- Speech Recognition
- Chatbots
- Self-driving cars

---

3 Real Life Example

Netflix Recommendation System

Netflix என்ன movies recommend செய்யும்?

அது analyze செய்யும்:

- watch history
- rating
- genre
- user behavior

இதற்கு **Advanced ML algorithms** பயன்படுத்தப்படும்.

---

4 Advanced ML பயன்படுத்தும் Fields

Advanced ML பயன்படுத்தப்படும் இடங்கள்:

🏥 Healthcare
📈 Stock market prediction
🚗 Self driving cars
🛒 Amazon recommendation
🎬 Netflix recommendation
🧠 ChatGPT போன்ற AI systems

5️⃣ Simple Example (Python)

```
from sklearn.ensemble import RandomForestClassifier
from sklearn.model_selection import train_test_split
from sklearn.datasets import load_iris

data = load_iris()

X = data.data
y = data.target

X_train,X_test,y_train,y_test = train_test_split(X,y,test_size=0.2)

model = RandomForestClassifier()
model.fit(X_train,y_train)

print(model.score(X_test,y_test))
```

இது ஒரு **Advanced ML algorithm (Random Forest)** example.

✅ **Final Simple Definition**

> **Advanced Machine Learning = complex data problems solve செய்ய advanced algorithms, feature engineering, tuning போன்ற techniques பயன்படுத்தும் ML.**

==========

📊 Feature Selection vs Dimension Reduction (எளிய விளக்கம்)

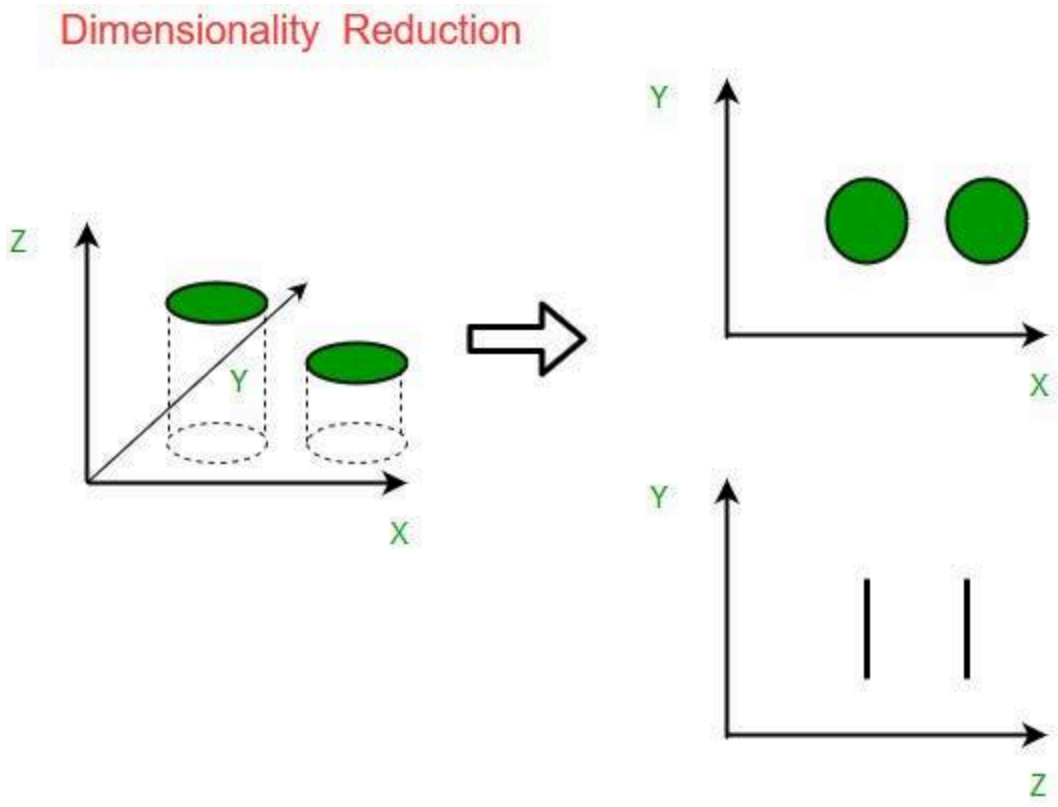

Dimensionality Reduction
&
Principal Component Analysis

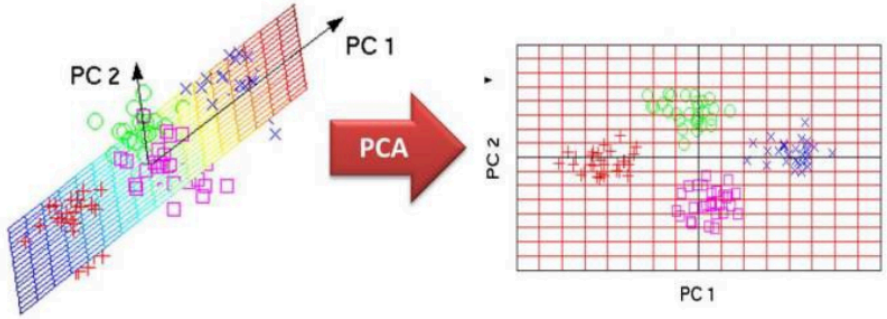

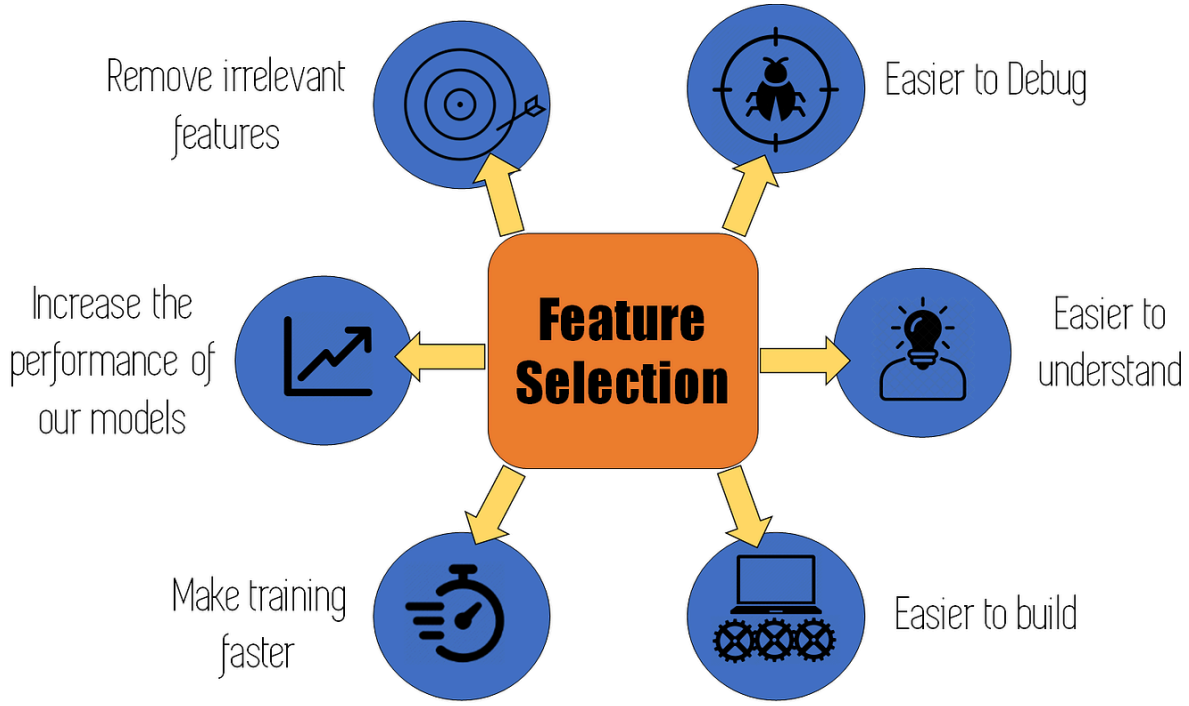

4

Machine Learning-ல் **data-**வில் இருக்கும் **features (columns)** அதிகமாக இருந்தால் model slow ஆகும், accuracy குறையலாம்.
அதனால் இரண்டு methods பயன்படுத்துவோம்:

- **Feature Selection**
- **Dimension Reduction**

இவை இரண்டும் **features** எண்ணிக்கையை குறைப்பதற்கான **methods**.

---

1 Feature Selection

Definition:

> Data-வில் இருக்கும் columns-லிருந்து **important columns** மட்டும் தேர்வு செய்வது.

Example

Student exam dataset:

Study Hours	Mobile Usage	Sleep	Shirt Color	Result
5	2	7	Red	Pass

இங்கே:

✔ Study Hours
✔ Sleep

❌ Shirt Color (Result-க்கு தொடர்பு இல்லை)

அதனால் **Shirt Color remove** செய்யப்படும்.

👉 இதுதான் **Feature Selection**.

Result Dataset

Study Hours	Sleep	Result

2️⃣ Dimension Reduction

Definition:

> பல features-ஐ **combine** செய்து புதிய குறைந்த **features** உருவாக்குவது.

இது original columns-ஐ remove செய்யாமல் **new features create** செய்யும்.

Example

ஒரு student dataset:

Math	Physics	Chemistry
80	75	78

இந்த 3 subjects-ஐ combine செய்து:

Science Score

அதாவது

Math + Physics + Chemistry → **Science Score**

👉 இது **Dimension Reduction**.

3️⃣ Simple Difference

Feature Selection	Dimension Reduction
Columns remove	Columns combine
Original features use	New features create
Simple method	Mathematical method
Example: remove Shirt Color	Example: PCA

4️⃣ Common Methods

Feature Selection

- Correlation
- Chi-Square
- Recursive Feature Elimination (RFE)
- Tree Importance

Dimension Reduction

- PCA (Principal Component Analysis)
- LDA
- t-SNE

5️⃣ Real Life Example

Face recognition system.

Image features:

- Eye position
- Nose shape
- Mouth shape
- Skin tone
- Face length

Feature selection → unnecessary features remove

Dimension reduction → **PCA use** செய்து **main face patterns** மட்டும் வைத்துக்கொள்வது

✅ **Short** நினைவில் வைத்துக்கொள்ள

Feature Selection
👉 useless columns remove

Dimension Reduction
👉 columns combine செய்து new feature create

==========

நீங்கள் கொடுத்த படத்தில் **Feature Selection Methods** மற்றும் **Dimensionality Reduction Methods** இரண்டும் காட்டப்பட்டுள்ளது. ஒவ்வொரு topic-ஐயும் எளிய தமிழில் **+ example** உடன் explain செய்கிறேன். 👇

1️⃣ SelectK Algorithm (SelectKBest)

என்ன இது?

Dataset-ல் இருக்கும் features-லிருந்து **top K important features** மட்டும் தேர்வு செய்வது.

- **K = எத்தனை features வேண்டுமோ அதை நாமே fix பண்ணலாம்**

எப்படி வேலை செய்கிறது?

Statistical test பயன்படுத்தி features score calculate செய்யும்.

Example tests:

- **Chi-Square**
- **ANOVA**
- **Mutual Information**

Example

Student result dataset:

Study Hours	Mobile Usage	Sleep	Result
5	2	7	Pass

Algorithm score calculate பண்ணும்.

Feature	Score
Study Hours	9.5
Sleep	8.2
Mobile Usage	2.1

K = 2 என்றால்:

✔ Study Hours
✔ Sleep

Mobile Usage remove.

2️⃣ Recursive Feature Elimination (RFE)

என்ன இது?

Step-by-step unnecessary features remove செய்யும் algorithm.

Recursive = repeated process.

எப்படி வேலை செய்கிறது?

1️⃣ Model train செய்யும்
2️⃣ Feature importance calculate
3️⃣ Least important feature remove
4️⃣ மீண்டும் model train

இப்படி repeat ஆகும்.

Example

House price prediction:

| Size | Location | Age | Owner Name |

Model importance:

Feature	Importance
Size	High
Location	High
Age	Medium
Owner Name	Low

👉 Owner Name remove.

3️⃣ Feature Importance

என்ன இது?

Model-ல் எந்த feature prediction-க்கு அதிகமாக contribute செய்கிறது என்று measure செய்வது.

இது mostly **Tree-based models**-ல் வரும்.

Example models:

- Random Forest
- Decision Tree
- XGBoost

Example

House price prediction

Feature	Importance
Size	0.60
Location	0.30
Age	0.08
Owner Name	0.02

👉 Owner Name useless.

4️⃣ Forward Selection

என்ன இது?

Initially **features** இல்லாமல் **start** செய்து important features ஒன்றாக add செய்வது.

எப்படி வேலை செய்கிறது?

Step-by-step feature add செய்து accuracy check பண்ணும்.

Example:

Start → no features

Step 1
Add Study Hours

Step 2
Add Sleep

Step 3
Mobile Usage add செய்தால் accuracy change இல்லை

👉 அதனால் add செய்யாது.

Final features:

✔ Study Hours
✔ Sleep

5️⃣ Backward Selection

என்ன இது?

Forward Selection-க்கு opposite.

👉 Initially **all features** இருக்கும்

பிறகு **least useful features remove**.

Example

| Study Hours | Mobile Usage | Sleep | Shirt Color |

Step 1 remove

❌ Shirt Color

Step 2 remove

❌ Mobile Usage

Final features

✔ Study Hours
✔ Sleep

6️⃣ Principal Component Analysis (PCA)

என்ன இது?

Dimensionality Reduction technique

பல features combine செய்து **new features create** செய்யும்.

Example

Image dataset:

| Pixel1 | Pixel2 | Pixel3 | Pixel4 | Pixel5 |

PCA apply செய்தால்

| Component1 | Component2 |

அதாவது

5 features → 2 features.

Model fast ஆகும்.

7️⃣ Linear Discriminant Analysis (LDA)

என்ன இது?

Classification problems-க்கு dimensionality reduction method

Classes-ஐ **best separation** செய்யும் **features create** செய்யும்.

Example

Spam email detection

Features:

- word frequency
- email length
- number of links

LDA → spam vs non-spam best separation create.

---

8 Kernel PCA

என்ன இது?

Normal PCA-வின் advanced version.

Non-linear relationships handle செய்யும்.

Example

Face recognition dataset.

Face features:

- eye distance
- nose length
- mouth shape

Relationship linear இல்லாமல் complex இருந்தால்

👉 Kernel PCA use.

🔑 Feature Selection vs Dimensionality Reduction

Feature Selection	Dimensionality Reduction
Columns remove	New features create
Original data keep	Data transform
Example: SelectKBest	Example: PCA

🎯 Real Life Example

Face recognition system.

Image features:

- eye distance
- nose shape
- face width
- skin color

Feature Selection
→ useless features remove

Dimensionality Reduction
→ PCA use செய்து face patterns reduce.

இந்த code-ல் உள்ள import statements எல்லாம் Python-ல் Machine Learning project செய்ய தேவையான libraries. ஒவ்வொன்றையும் எதற்காக பயன்படுத்துகிறோம் + simple example உடன் explain செய்கிறேன். 👇

1️⃣ import pandas as pd

Pandas → Data analysis library.

👉 **Dataset (CSV / Excel) load செய்ய மற்றும் table format-ல் data handle செய்ய.**

Example:

```
import pandas as pd


data = pd.read_csv("data.csv")

print(data.head())
```

Use:

- **dataset read**
- **data cleaning**
- **column selection**

2️⃣ from sklearn.model_selection import train_test_split

Dataset-ஐ training data மற்றும் testing data ஆக split செய்ய.

Machine learning model train செய்ய training data பயன்படுத்தும்
model accuracy check செய்ய testing data பயன்படுத்தும்.

Example:

X_train, X_test, y_train, y_test = train_test_split(X, y, test_size=0.2)

80% training
20% testing

---

3 import time

Program execution time measure செய்ய.

Example:

```
start = time.time()


# code


end = time.time()

print("Time:", end-start)
```

Use:

- **model training time measure**

---

4 import numpy as np

NumPy → Numerical computation library.

Matrix, array operations fast ஆக செய்ய.

Example:

```
import numpy as np
```

a = np.array([1,2,3])

print(a.mean())

Use:

- **mathematical operations**
- **matrix calculations**

---

5 from sklearn.preprocessing import StandardScaler

Data scaling செய்ய.

Features values different range இருந்தால் model performance குறையும்.

Example:

Age	Salary
25	20000
45	80000

Scale செய்தால்:

Age	Salary

0.2 0.5

Example code:

scaler = StandardScaler()

X = scaler.fit_transform(X)

6️⃣ from sklearn.feature_selection import SelectKBest

Feature Selection method

Top K important features மட்டும் select செய்யும்.

Example:

selector = SelectKBest(score_func=chi2, k=5)

X_new = selector.fit_transform(X, y)

Meaning:

Dataset-ல் இருந்து 5 important features மட்டும் select.

7️⃣ from sklearn.feature_selection import chi2

Chi-square statistical test.

Feature மற்றும் target relationship strong இருக்கிறதா என்று check செய்ய.

Use:

- classification problems
- feature ranking

Example:

selector = SelectKBest(chi2, k=5)

---

8 from sklearn.feature_selection import RFE

Recursive Feature Elimination.

Step-by-step unnecessary features remove செய்யும்.

Example:

model = LogisticRegression()

rfe = RFE(model, n_features_to_select=5)

X_rfe = rfe.fit_transform(X, y)

Meaning:

Best 5 features மட்டும் select.

---

9 from sklearn.linear_model import LogisticRegression

Classification algorithm.

Binary classification problems:

Example:

- **spam email detection**
- **disease prediction**
- **pass/fail prediction**

Example code:

```
model = LogisticRegression()
model.fit(X_train, y_train)
```

🔟 import pickle

Machine learning model save செய்ய.

Model train செய்த பிறகு file ஆக save செய்யலாம்.

Example:

```
pickle.dump(model, open("model.pkl", "wb"))
```

Later load செய்யலாம்:

```
model = pickle.load(open("model.pkl", "rb"))
```

1️⃣1️⃣ import matplotlib.pyplot as plt

Charts / graphs plot செய்ய.

Example:

```
plt.plot([1,2,3],[10,20,30])
plt.show()
```

Use:

- data visualization
- accuracy graph
- feature importance plot

📊 Simple Summary

Library	Use
Pandas	Data analysis
NumPy	Mathematical operations
train_test_split	Dataset split
StandardScaler	Data scaling
SelectKBest	Feature selection
chi2	Feature importance test
RFE	Feature elimination

LogisticRegression	**Classification model**
pickle	**Model save/load**
matplotlib	**Graph plotting**

✅ **Short explanation**

இந்த imports எல்லாம் Machine Learning pipeline build செய்ய பயன்படுத்தப்படும் tools.

Steps usually:

1️⃣ **Load data → pandas**
2️⃣ **Process data → numpy**
3️⃣ **Split data → train_test_split**
4️⃣ **Scale data → StandardScaler**
5️⃣ **Select features → SelectKBest / RFE**
6️⃣ **Train model → LogisticRegression**
7️⃣ **Save model → pickle**
8️⃣ **Visualize result → matplotlib**

💡 **வேண்டுமானால் நான் உங்கள் code based ஆக full ML pipeline diagram explain கூட செய்யலாம் (Data Science interview level).**

with example explain eacch

நீங்கள் கொடுத்த ஒவ்வொரு import-க்கும் ஒரு simple example கொடுத்து explain செய்கிறேன். இது ஒரு Machine Learning pipeline எப்படி வேலை செய்கிறது என்பதை புரிய உதவும்.

1️⃣ `import pandas as pd`

Purpose: Dataset (CSV/Excel) load செய்து table format-ல் handle செய்ய.

Example

```
import pandas as pd


data = pd.read_csv("students.csv")

print(data.head())
```

Example dataset:

Hours	Sleep	Result
5	7	Pass
2	5	Fail

👉 **Pandas data read மற்றும் analyse செய்ய உதவும்.**

2️⃣ from sklearn.model_selection import train_test_split

Purpose: Dataset-ஐ training மற்றும் testing data ஆக split செய்ய.

Example

```
from sklearn.model_selection import train_test_split


X = data[['Hours','Sleep']]
```

```
y = data['Result']


X_train, X_test, y_train, y_test = train_test_split(X,y,test_size=0.2)
```

Meaning:

- **80% data → training**
- **20% data → testing**

---

3 import time

Purpose: Program run time measure செய்ய.

Example

```
import time


start = time.time()


print("Model training...")


end = time.time()


print("Time:", end-start)
```

Output:

Time: 0.02 seconds

4️⃣ import numpy as np

Purpose: Mathematical calculations மற்றும் arrays.

Example

```
import numpy as np


numbers = np.array([10,20,30])


print(numbers.mean())
```

Output

20

👉 **Mean, matrix operations போன்றவை fast ஆக செய்யலாம்.**

5️⃣ from sklearn.preprocessing import StandardScaler

Purpose: Data scaling.

Example dataset:

Age	Salary
25	20000
40	80000

Values different range இருக்கிறது.

Example

```
from sklearn.preprocessing import StandardScaler


scaler = StandardScaler()


X_scaled = scaler.fit_transform(X)
```

Result:

Age	Salary
-0.5	-0.3
0.8	1.2

👉 **Model accuracy improve ஆகும்.**

6️⃣ `from sklearn.feature_selection import SelectKBest`

Purpose: Top important features மட்டும் select செய்ய.

Example dataset:

Study	Sleep	Mobile	Result

Example

```
from sklearn.feature_selection import SelectKBest

from sklearn.feature_selection import chi2


selector = SelectKBest(score_func=chi2,k=2)


X_new = selector.fit_transform(X,y)
```

Meaning:

👉 **Best 2 features மட்டும் select**

Example result:

| Study | Sleep |

7️⃣ from sklearn.feature_selection import chi2

Purpose: Feature importance measure செய்ய.

Example:

Feature	Score
Study Hours	9.5
Sleep	7.3

Mobile	1.2

👉 High score = important feature.

8️⃣ from sklearn.feature_selection import RFE

Purpose: Recursive Feature Elimination.

Step-by-step useless features remove செய்யும்.

Example

Dataset:

| Size | Location | Age | Owner |

Model importance:

Feature	Importance
Size	High
Location	High
Age	Medium
Owner	Low

👉 **Owner remove.**

Code:

```
from sklearn.feature_selection import RFE

from sklearn.linear_model import LogisticRegression


model = LogisticRegression()


rfe = RFE(model, n_features_to_select=2)


X_rfe = rfe.fit_transform(X,y)
```

9️⃣ from sklearn.linear_model import LogisticRegression

Purpose: Classification algorithm.

Example problem:

Predict

Pass / Fail

Example

```
from sklearn.linear_model import LogisticRegression


model = LogisticRegression()


model.fit(X_train,y_train)
```

pred = model.predict(X_test)

Output:

Pass

Fail

Pass

🔟 import pickle

Purpose: Trained model save செய்ய.

Example

import pickle

pickle.dump(model,open("model.pkl","wb"))

Later load செய்ய:

model = pickle.load(open("model.pkl","rb"))

👉 ML deployment-ல் மிகவும் important.

1️⃣1️⃣ import matplotlib.pyplot as plt

Purpose: Graph plot செய்ய.

Example

import matplotlib.pyplot as plt

```
x=[1,2,3]

y=[10,20,30]


plt.plot(x,y)


plt.show()
```

Graph display ஆகும்.

🎯 Full ML Pipeline Example

Steps:

1️⃣ Load data → pandas
2️⃣ Split data → train_test_split
3️⃣ Scale data → StandardScaler
4️⃣ Select features → SelectKBest
5️⃣ Train model → LogisticRegression
6️⃣ Save model → pickle
7️⃣ Visualize result → matplotlib

✅ **Short Summary**

Library	Example Use
Pandas	Dataset load
NumPy	Mathematical operations

train_test_split	**Data split**
StandardScaler	**Data scaling**
SelectKBest	**Best features select**
RFE	**Remove useless features**
LogisticRegression	**Train model**
pickle	**Save model**
matplotlib	**Grap**

==========

நீங்கள் கொடுத்த code ஒரு **Machine Learning classification pipeline**.
இதன் purpose: **Feature selection** செய்து பல **ML algorithms train** செய்து **accuracy compare** செய்வது.

ஒவ்வொரு function-யும் ஏன் பயன்படுத்துகிறோம் என்பதை simple-ஆ explain செய்கிறேன்.

1️⃣ `selectkbest(indep_X, dep_Y, n)`

Purpose

Dataset-ல் இருந்து **important features** மட்டும் **select** செய்ய.

`SelectKBest + Chi-Square` method பயன்படுத்துகிறது.

Meaning

- `indep_X` → input features
- `dep_Y` → target column
- `n` → எத்தனை features வேண்டுமோ

Example

Dataset:

Age	Salary	City	Buy

Suppose

`n = 2`

Result:

| Age | Salary |

👉 Best 2 features மட்டும் select.

2️⃣ `split_scalar(indep_X, dep_Y)`

Purpose

Dataset-ஐ **training + testing data ஆக split** செய்து **data scaling** செய்ய.

Steps:

1. Train test split
2. Standard scaling

Code meaning

train_test_split(... test_size = 0.25)

25% → testing
75% → training

Example:

100 rows dataset

75 → training
25 → testing

3️⃣ `cm_prediction(classifier, X_test)`

Purpose

Model prediction result evaluate செய்ய.

இதில் 3 things calculate செய்கிறது:

1️⃣ **Confusion Matrix**
2️⃣ **Accuracy**
3️⃣ **Classification Report**

Example:

Actual	Predicted
Pass	Pass
Fail	Pass

Confusion matrix example:

	Pred Pass	Pred Fail
Actual Pass	20	3
Actual Fail	4	18

4️⃣ `logistic(X_train, y_train, X_test)`

Purpose

Logistic Regression model train செய்ய.

Use case:

- Binary classification

- Pass / Fail
- Disease prediction

Steps:

1. Model create
2. Model train
3. Prediction evaluate

5️⃣ `svm_linear(X_train, y_train, X_test)`

Purpose

Support Vector Machine (Linear Kernel) model train செய்ய.

Best for:

- Linear datasets
- High dimensional data

Example:

Spam vs Non-spam classification.

6️⃣ `svm_NL(X_train, y_train, X_test)`

Purpose

Non-linear SVM (RBF Kernel).

Used when dataset linear இல்லை.

Example:

Image classification
Face recognition.

7️⃣ Navie(X_train, y_train, X_test)

Purpose

Naive Bayes classifier train செய்ய.

Best for:

- Text classification
- Spam detection
- Email filtering

Example:

Email → Spam / Not spam.

8️⃣ knn(X_train, y_train, X_test)

Purpose

K-Nearest Neighbor algorithm train செய்ய.

Concept:

Nearest data points பார்த்து prediction.

Example:

Student marks predict.

Nearest 5 students average.

9️⃣ Decision(X_train, y_train, X_test)

Purpose

Decision Tree model train செய்ய.

Decision rules based model.

Example:

Age > 30?

yes → buy

no → not buy

🔟 random(X_train, y_train, X_test)

Purpose

Random Forest model train செய்ய.

Random forest = many decision trees.

Advantages:

- Higher accuracy
- Less overfitting

Example:

Stock prediction
Credit risk prediction.

1️⃣1️⃣ `selectk_Classification(...)`

Purpose

All model accuracies compare செய்து **table create** செய்ய.

Example output:

Method	Logistic	SVM	KNN	NB	DT	RF
ChiSquare	85%	87%	82%	80%	84%	90%

👉 Which model best என்று தெரியும்.

🔎 Overall Pipeline

இந்த code என்ன செய்கிறது?

Step-by-step:

1️⃣ Feature selection (SelectKBest)
2️⃣ Data split + scaling

3️⃣ Train multiple ML models
4️⃣ Evaluate models
5️⃣ Compare accuracy

✅ **One line summary**

> This code selects important features, trains multiple machine learning classifiers, evaluates them, and compares their accuracy.

==========

💡 **வேண்டுமானால் நான் இந்த code-க்கு super easy flowchart diagram (1 minute-ல் புரியும்) explain செய்யலாம். இது Data Science viva-க்கு மிகவும் useful.**

super easy flowchart diagram (1 minute-ல் புரியும்)

Machine Learning Pipeline – Super Easy Flow (1-minute understanding)

==========

Start

|

▼

Load Dataset

(indep_X , dep_Y)

|

▼

Feature Selection

SelectKBest + Chi2

(important features only)

│

▼

Split Data

Train (75%) / Test (25%)

│

▼

Data Scaling

(StandardScaler)

│

▼

Train Multiple Models

├─ Logistic Regression

├─ SVM Linear

├─ SVM Non-Linear (RBF)

├─ KNN

├─ Naive Bayes

├─ Decision Tree

└─ Random Forest

│

▼

Prediction

(Model predicts test data)

│

```
  ▼
Evaluation
  ├─ Confusion Matrix
  ├─ Accuracy
  └─ Classification Report
  │
  ▼
Compare Results
(Create accuracy table)
  │
  ▼
Best Model Identified
  │
  ▼
End
==================================
```

ataset1=pd.read_csv("prep.csv",index_col=None) df2=dataset1 df2 = pd.get_dummies(df2, drop_first=True) indep_X=df2.drop('classification_yes', axis=1) dep_Y=df2['classification_yes'] above uses

இந்த code **dataset-ஐ machine learning model-க்கு prepare** செய்ய பயன்படுத்தப்படுகிறது. ஒவ்வொரு line-ஐ simple explanation + example உடன் பார்க்கலாம்.

1

```
dataset1 = pd.read_csv("prep.csv", index_col=None)
```

Purpose

CSV file-ல் இருக்கும் dataset-ஐ **Python-க்கு load** செய்ய.

Example:

`prep.csv`

age	salary	classification
25	20000	yes
40	60000	no

இந்த dataset **dataset1 variable-ல் load** ஆகும்.

2

```
df2 = dataset1
```

Purpose

Original dataset-ஐ **copy** செய்து **new variable-ல் store** செய்ய.

Why?

Original data change ஆகாமல் இருக்க.

Example:

dataset1 → original data
df2 → working data

3

```
df2 = pd.get_dummies(df2, drop_first=True)
```

Purpose

Categorical data-ஐ **numeric format-ஆ convert** செய்ய.

Machine learning models numbers மட்டும் accept செய்யும்.

Example:

Before:

age	classification
25	yes
40	no

After dummy encoding:

age	classification_yes
25	1
40	0

👉 `drop_first=True` redundant column avoid செய்ய.

4️⃣

indep_X = df2.drop('classification_yes', axis=1)

Purpose

Independent variables (features) select செய்ய.

Target column remove செய்யப்படுகிறது.

Example:

age	salary

5️⃣

dep_Y = df2['classification_yes']

Purpose

Dependent variable (target) select செய்ய.

Example:

classification_yes
1
0

Meaning:

1 → yes
0 → no

📊 Final Data Structure

Features (X)

age	salary
25	20000
40	60000

Target (Y)

classification_yes

1

0

🎯 Overall Purpose (One Line)

> This code loads the dataset, converts categorical data into numeric form, and separates the features (X) and target variable (Y) for machine learning.

💡 வேண்டுமானால் நான் இந்த **dataset preparation process-க்கு simple diagram** கூட காட்டலாம். இது Data Science exam-ல் மிகவும் helpful.

best=selectkbest(indep_X,dep_Y,6) acclog=[] accsvml=[] accsvmnl=[] accknn=[] accnav=[] accdes=[] accrf=[] above use

இந்த code **feature selection** செய்து, **different machine learning models accuracy store** செய்ய பயன்படுத்தப்படுகிறது. ஒவ்வொரு line-ஐ simple-ஆ explain செய்கிறேன்.

1️⃣

best = selectkbest(indep_X, dep_Y, 6)

Purpose

Dataset-ல் இருந்து **6 important features** மட்டும் **select** செய்ய.

Function used:
`SelectKBest + Chi-Square`

Meaning:

- `indep_X` → all input features
- `dep_Y` → target column
- `6` → best **6 features select**

Example:

Before:

| Age | Salary | City | Gender | Job | Experience | Education |

After feature selection:

| Age | Salary | Experience | Job | Education | Gender |

👉 Most important **6 columns** மட்டும் இருக்கும்.

2️⃣

acclog=[]

Purpose

Logistic Regression accuracy store செய்ய list create.

Example later:

acclog.append(0.88)

List becomes:

[0.88]

3️⃣

accsvml=[]

Purpose

Linear SVM model accuracy store செய்ய list.

Example:

[0.90]

4

accsvmnl=[]

Purpose

Non-Linear SVM (RBF kernel) accuracy store செய்ய list.

Example:

[0.91]

5

accknn=[]

Purpose

K-Nearest Neighbor model accuracy store செய்ய list.

Example:

[0.86]

6

accnav=[]

Purpose

Naive Bayes model accuracy store செய்ய list.

Example:

[0.82]

7

accdes=[]

Purpose

Decision Tree model accuracy store செய்ய list.

Example:

[0.87]

8️⃣

accrf=[]

Purpose

Random Forest model accuracy store செய்ய list.

Example:

[0.93]

📊 Why we create these lists?

Later each model accuracy add செய்யப்படும்:

Example result:

```
acclog  = [0.88]
accsvml = [0.90]
accsvmnl= [0.91]
accknn  = [0.86]
accnav  = [0.82]
accdes  = [0.87]
accrf   = [0.93]
```

இந்த values use செய்து **model comparison table create** செய்யலாம்.

==========

```
X_train, X_test, y_train, y_test=split_scalar(kbest,dep_Y)
classifier,Accuracy,report,X_test,y_test,cm=logistic(X_train,y_train,X_test)
acclog.append(Accuracy)
classifier,Accuracy,report,X_test,y_test,cm=svm_linear(X_train,y_train,X_test)
accsvml.append(Accuracy)
classifier,Accuracy,report,X_test,y_test,cm=svm_NL(X_train,y_train,X_test)
accsvmnl.append(Accuracy)
classifier,Accuracy,report,X_test,y_test,cm=knn(X_train,y_train,X_test)
accknn.append(Accuracy)
classifier,Accuracy,report,X_test,y_test,cm=Navie(X_train,y_train,X_test)
accnav.append(Accuracy)
classifier,Accuracy,report,X_test,y_test,cm=Decision(X_train,y_train,X_test)
accdes.append(Accuracy)
classifier,Accuracy,report,X_test,y_test,cm=random(X_train,y_train,X_test)
accrf.append(Accuracy)
result=selectk_Classification(acclog,accsvml,accsvmnl,accknn,accnav,accdes,accrf) above use
```

இந்த code block **selected features (kbest)** கொண்டு பல **machine learning models train** செய்து **accuracy compare** செய்ய பயன்படுத்தப்படுகிறது. ஒவ்வொரு step-யும் simple explanation பார்க்கலாம்.

1️⃣

X_train, X_test, y_train, y_test = split_scalar(kbest, dep_Y)

Purpose

Dataset-ஐ **training** மற்றும் **testing data** ஆக **split** செய்து **scaling** செய்ய.

- `kbest` → selected best features
- `dep_Y` → target column

Inside function:

- **75% → Training data**
- **25% → Testing data**

- `StandardScaler` → data normalize

Example:

100 rows dataset

- 75 rows → training
- 25 rows → testing

2️⃣

```
classifier,Accuracy,report,X_test,y_test,cm = logistic(X_train,y_train,X_test)
acclog.append(Accuracy)
```

Purpose

Logistic Regression model train செய்து **accuracy calculate** செய்ய.

Result:

- Confusion Matrix
- Accuracy
- Classification report

Accuracy value **acclog list-ல் store** செய்யப்படுகிறது.

Example:

```
Accuracy = 0.87
acclog = [0.87]
```

3️⃣

```
classifier,Accuracy,report,X_test,y_test,cm = svm_linear(X_train,y_train,X_test)
```

accsvml.append(Accuracy)

Purpose

Linear SVM model train செய்ய.

Accuracy value **accsvml list-ல் store** செய்யப்படுகிறது.

Example:

accsvml = [0.89]

4

classifier,Accuracy,report,X_test,y_test,cm = svm_NL(X_train,y_train,X_test)
accsvmnl.append(Accuracy)

Purpose

Non-linear SVM (RBF kernel) model train செய்ய.

Example:

accsvmnl = [0.91]

5

classifier,Accuracy,report,X_test,y_test,cm = knn(X_train,y_train,X_test)
accknn.append(Accuracy)

Purpose

K-Nearest Neighbors algorithm train செய்ய.

Example:

accknn = [0.85]

6

```
classifier,Accuracy,report,X_test,y_test,cm = Navie(X_train,y_train,X_test)
accnav.append(Accuracy)
```

Purpose

Naive Bayes classifier train செய்ய.

Example:

accnav = [0.82]

7

```
classifier,Accuracy,report,X_test,y_test,cm = Decision(X_train,y_train,X_test)
accdes.append(Accuracy)
```

Purpose

Decision Tree model train செய்ய.

Example:

accdes = [0.88]

8

```
classifier,Accuracy,report,X_test,y_test,cm = random(X_train,y_train,X_test)
accrf.append(Accuracy)
```

Purpose

Random Forest model train செய்ய.

Example:

accrf = [0.93]

9

result = selectk_Classification(acclog,accsvml,accsvmnl,accknn,accnav,accdes,accrf)

Purpose

All models accuracy-ஐ ஒரு **table-ல் compare** செய்ய.

Example output:

Method	Logistic	SVM Linear	SVM RBF	KNN	NB	DT	RF
ChiSquare	0.87	0.89	0.91	0.85	0.82	0.88	0.93

👉 Best model identify செய்ய உதவும்.

⭐ Overall Process

இந்த code என்ன செய்கிறது?

Best Features → Split Data → Train 7 Models →
Calculate Accuracy → Store Results → Compare Models

✅ One line explanation

> This code splits the selected features dataset, trains multiple classification models, stores their accuracies, and compares the models to find the best one.

==========